Aprendizagem de maquina
Proposta de Projeto: O Desafio do Oráculo Preditivo

Esta atividade tem como objetivo aplicar e consolidar os conhecimentos adquiridos sobre algoritmos de regressão (como Regressão Linear Simples e Multipla, Random Forest Regressor - RFR, Support Vector Regressor - SVR, entre outros).

PARTE I

Grupo	Data set	Nota
01 **Apolo** **Nicolas** **Caio** **Gabriel**	Ecommerce Customers https://www.kaggle.com/datasets/iyadavvaibhav/ecommerce-customer-device-usage	
02 **Milton** **Gustavo Molina** **João Emanoel** **Murilo**	Car Price Prediction https://www.kaggle.com/datasets/nehalbirla/vehicle-dataset-from-cardekho	
03 **Erika** **Felipe** **Matheus** **Ruylis**	Uber Fares Dataset https://www.kaggle.com/code/moham9/uber-fares-group-project/input	
04 **Reinaldo** **Veronica** **Jonatas**	Graduate Admission https://www.kaggle.com/datasets/mohansacharya/graduate-admissions	
05 **Gustavo Bravo** **Gustavo Martins** **Thiago** **Lucas**	Health and Lifestyle Data https://www.kaggle.com/datasets/pratikyuvrajchougule/health-and-lifestyle-data-for-regression	
06 **Clara** **Barbara** **Jacqueline**	Medical Cost Personal Datasets https://www.kaggle.com/datasets/mirichoi0218/insurance	

a) Modelo de Relatório: Desafio do Oráculo Preditivo

1) Resumo

2) Introdução e Contextualização

Apresentem brevemente o problema que o dataset propõe resolver. Qual é a variável alvo (target) e quais são as principais variáveis preditoras (features)?

3) Objetivos do projeto

O objetivo é realizar uma análise comparativa entre três abordagens de regressão para prever um valor contínuo, identificando qual modelo possui o melhor poder de generalização e explicando o porquê da superioridade (ou inferioridade) de cada técnica frente à natureza dos dados.

4) Análise Exploratória (EDA): *Descrever as principais descobertas sobre os dados:*

- **Distribuição da Variável Alvo:** Ex: "A variável preço apresenta uma assimetria à direita").
- **Correlações:** Quais variáveis mais influenciam o resultado final? Apresentem o Heatmap de correlação.
- **Outliers:** Como foram identificados e qual foi a decisão tomada (remoção, tratamento ou manutenção)?

5) Pré-processamento e Engenharia de Features: Explicar os passos técnicos tomados antes de treinar os modelos:

- **Tratamento de variáveis Categóricos:** (Ex: One-Hot Encoding ou Label Encoding).
- **Escalonamento:** Foi utilizada Padronização (*StandardScaler*) ou Normalização (*MinMaxScaler*)? Justificar (obrigatório para SVR e útil para Regressão Linear).
- **Divisão dos Dados:** Qual a proporção utilizada para Treino e Teste?
- **Treinamento e Ajuste de Hiperparâmetros:** Uso de *Cross-Validation* para evitar overfitting.

5) Modelagem e Implementação dos seguintes Algoritmos Supervisionado:

Cada grupo deve implementar, ajustar e validar:

a) **Regressão Linear Múltipla:** Como baseline estatístico.
b) **Random Forest Regressor:** Para capturar relações não-lineares e interações complexas.
c) **SVR (Support Vector Regression):** Para testar a robustez com kernels (RBF/Linear).

6) Validação e analise Comparativa (Métricas de Avaliação): Utilização obrigatória das métricas de performance.

Os alunos deverão apresentar uma tabela comparativa com:

- **Coeficiente de Determinação (R^2):** Para medir a proporção da variância explicada.
- **Erro Médio Absoluto (MAE):** Para entender o erro médio em unidades reais.
- **Erro Percentual Absoluto Médio (MAPE):** Para comunicar o erro em termos percentuais (ótimo para apresentações executivas).
- **RMSE (Root Mean Squared Error):** Para penalizar erros de grande magnitude.

Apresentem os resultados obtidos após o treinamento e ajuste de hiperparâmetros.

Tabela Comparativa de Métricas

Modelo	R2	MAE	MAPE (%)	RMSE
Regressão Linear Múltipla				
Random Forest Regressor				
Support Vector Regressor (SVR)				

7) Critérios para a "Escolha do Melhor Algoritmo"

Cada grupo deverá não somente procurar encontrar o R^2 mais alto, mas justificar a escolha baseando-se em:

1. **Resíduos:** O gráfico de resíduos apresenta padrão? (Se sim, o modelo falhou em capturar alguma informação).
2. **Overfitting:** A diferença entre o erro de treino e o de teste é muito grande?
3. **Interpretabilidade:** O modelo precisa ser explicável ou apenas preciso?
   Dica Pedagógica: Elaborar gráfico de **"Valores Reais vs. Valores Preditos"** para os três modelos em um mesmo painel. Visualmente, a proximidade dos pontos à linha de 45° é o argumento mais convincente para um aluno iniciante.

8) Visualização de Performance

*Insiram aqui os gráficos de **"Valores Reais vs. Valores Preditos"** para cada um dos três modelos.*

9) Discussão e Veredito Final

Esta é a parte mais importante do trabalho. Respondam:

1. Qual modelo obteve a melhor performance global e por quê?
2. Houve sinais de **overfitting** (erro de treino muito menor que o de teste)?
3. Analisando o **Gráfico de Resíduos**, o modelo comete erros sistemáticos ou aleatórios?
4. Considerando o uso prático desse modelo em uma empresa, vocês recomendariam o modelo mais complexo (ex: RFR) ou o mais simples (Linear)? **Justifiquem com base no equilíbrio entre precisão e interpretabilidade.**

10) Referências Bibliograficas

Citem bibliotecas (Scikit-Learn, Pandas, etc), artigos ou livros utilizados para fundamentar as decisões técnicas.

PARTE II

Estas perguntas visam testar se os alunos compreendem a **causalidade** e a **teoria** por trás dos algoritmos, indo além da simples execução de bibliotecas como Scikit-Learn ou o uso de ferramentas visuais.

Roteiro de Arguição Técnica: Projetos de Regressão

1) Eixo: Tratamento de Dados e Premissas Estatísticas

Fundamentação: Teorema de Gauss-Markov e Sensibilidade de Algoritmos baseados em Distância.

- **Pergunta:** "Para a Regressão Linear, vocês verificaram a **Multicolinearidade** entre as variáveis independentes? Como a presença de variáveis altamente correlacionadas afeta os coeficientes do modelo?"
- **Pergunta:** "O **SVR** e a **Regressão Linear** são sensíveis à escala dos dados. Qual técnica de normalização ou padronização foi utilizada e por que isso é crítico especificamente para o funcionamento do Kernel no SVR?"
- **Pergunta:** "Como o grupo lidou com **Outliers**? Baseado na fundamentação teórica, qual dos três algoritmos escolhidos é inerentemente mais robusto a valores discrepantes e por quê?"

2) Eixo: Complexidade e Arquitetura dos Modelos

Fundamentação: Trade-off Viés-Variância (Bias-Variance Tradeoff).

- **Pergunta:** "O **Random Forest** é um método de *Ensemble* (Bagging). Como a profundidade das árvores e o número de estimadores influenciam no risco de **Overfitting** neste projeto?"
- **Pergunta:** "No caso do **SVR**, qual foi o critério para a escolha do **Kernel** (Linear, RBF, Polinomial)? Como essa escolha altera a dimensão do espaço de características onde o hiperplano de regressão é construído?"
- **Pergunta:** "Se a relação entre as variáveis fosse estritamente linear, o Random Forest ainda seria a melhor escolha? Justifiquem com base na complexidade do modelo."

3) Eixo: Métrica e Interpretação de Performance
Fundamentação: Teoria da Estimação e Erro Quadrático vs. Erro Absoluto.

- **Pergunta:** "Observando o **MAE** e o **RMSE**, houve uma discrepância significativa entre eles? Se o RMSE for muito superior ao MAE, o que isso nos diz sobre a magnitude dos erros que o modelo está cometendo?"
- **Pergunta:** "O $\mathbf{R^2}$ (Coeficiente de Determinação) foi alto, mas o modelo performou bem em dados de teste nunca vistos? Expliquem a importância da Validação Cruzada (*Cross-Validation*) para garantir que essas métricas sejam confiáveis."
- **Pergunta:** "Por que utilizamos o **MAPE** para explicar os resultados para um público não técnico (ex: diretoria de uma empresa) em vez de usar apenas o erro quadrático?"

4) Eixo: Tomada de Decisão e Recomendação
Fundamentação: Navalha de Ockham (Simplicidade vs. Performance).

- **Pergunta:** "Considerando que a Regressão Linear é muito mais simples e rápida de computar, o ganho de performance obtido com o Random Forest ou SVR justifica a perda de **interpretabilidade** do modelo?"
- **Pergunta:** "Se este modelo fosse colocado em produção para prever dados em tempo real (milhares de requisições por segundo), qual algoritmo vocês recomendariam considerando o custo computacional de predição?"

Critérios de avaliação

Critério	Peso	O que observar
Domínio Teórico	30%	Se sabem explicar a diferença entre os kernels e a lógica do ensemble.
Rigor Metodológico	30%	Uso correto de treino/teste, escalonamento e tratamento de nulos.
Análise de Métricas	20%	Capacidade de interpretar os erros (não apenas ler números).
Defesa da Escolha	20%	Coerência entre os dados apresentados e a recomendação final.

Orientações para Entrega:

- **Formato:** PDF (preferencialmente gerado a partir de um Jupyter Notebook ou Markdown).
- **Código:** O link do repositório (GitHub) ou o arquivo do projeto (.py, .ipynb) deve acompanhar este relatório. O Dashboard com Streamlit
- **Enviar pelo Teams:**
- **Data Limite:** 30/09/2026
- **Horario da apresentação:** 7h40

Dica para os alunos: "Métricas excelentes em dados de treino não garantem um bom modelo. O que define um bom cientista de dados é a capacidade de fazer o modelo performar bem em dados que ele nunca viu antes."